

① سوال

$$\log P_{\theta}(x) = \log \sum_z P_{\theta}(x, z) \quad (1)$$

$$= \log \sum_z q(z) \frac{P_{\theta}(x, z)}{q(z)} \geq \sum_z q(z) \log \frac{P_{\theta}(x, z)}{q(z)}$$

$$= \sum_z q(z) \frac{P_{\theta}(x|z) P_{\theta}(z)}{q(z)} = E$$

$$= \underbrace{E_{q(z)} [\log P_{\theta}(x|z)]}_{\text{ELBO}} - \text{KL} (q(z) || P_{\theta}(z))$$

ELBO

(2)

$\theta, \Psi_{1:N}, N$: ۱) پارامترهای روی روز را بصورت ندوم مقدار دهی اولیه می‌کنیم

: ۲) با این پارامترها ELBO را بسطیزی کنیم

$$\sum_{i=1}^N \max_{q \in Q} \text{ELBO}(q_{\Psi_i}, x_i, \theta)$$

در یک while loop در میانه بررسی ELBO بینه بینه می‌گذرد و با استفاده از Converge

ادامه می‌کند تا عدد N داده شده از پارامترها را بصورت نزیر محاسبه کند:

$$\Psi_i \leftarrow \arg \max_{\Psi_i} L(\Psi_i, \theta; x_i)$$

با این پارامترها کردن و با استفاده از loop 8 مرتبه ای از این دستور (4)

$$\theta \leftarrow \arg \max_{\theta} \sum_{i=1}^N L(x_i; \Psi_i, \theta) \quad : \theta \text{ را محاسبه می‌کنیم}$$

اداہ ۲) نتیجه‌گیری زمانی ها که در این مسوده بینه بررسی حلقة while را اداه می‌دهم.

(3)

الف) مثل الگوریتم بیشتر میل عملیاتی آن در اینجا B) داده در هر چند داریم سپس در ۱۰۰ پا ابتدا B , θ , ψ سهیل برای Batch در نظر می‌گیریم.

سپس تراویانهای $(\alpha_j; \psi_j; \theta)$ را می‌گیریم و بازی هر سهیل می‌گیریم. در نهایت تراویان را می‌گیریم و میانگین تراویانهای می‌گیریم. در مرحله بعد برای آپدیت ψ , θ محاسبات زیر انجام می‌شود:

$$\frac{1}{B} \sum_j \nabla_{\psi_j} L(\alpha^B; \psi^B, \theta) \quad \text{و} \quad \frac{1}{B} \sum_j \nabla_{\theta} L(\alpha^B; \psi^B, \theta)$$

$$\left\{ \begin{array}{l} \bar{\nabla}_{\psi_j} L(\alpha^B; \psi^B, \theta) \triangleq [I(\psi)]^{-1} \hat{\nabla}_{\psi^B} L(\alpha^B; \psi^B, \theta) \\ \psi_j \leftarrow \text{آپدیت می‌کنیم} \end{array} \right.$$

$$\left\{ \begin{array}{l} \bar{\nabla}_{\theta} L(\alpha^B; \psi^B, \theta) \triangleq [I(\theta)]^{-1} \hat{\nabla}_{\theta} L(\alpha^B; \psi^B, \theta) \\ \theta \leftarrow \text{آپدیت می‌کنیم} \end{array} \right.$$

سپس مراحل زیر برای محاسبه ELBO:

$$\hat{L}(\alpha^B; \psi^B, \theta) = \sum_{i=1}^B L(\alpha_i; \psi_i, \theta)$$

$$L(\alpha; \psi_{1:N}, \theta) = \frac{N}{B} \hat{L}(\alpha^B; \psi^B, \theta)$$

(3) ب) در این حالت $\Psi_{1:N}$ نمایم: پس در مرحله اول ϕ و θ مقدار دهی

اولیه می شوند.

پس مثل حالات قبلی که این هر داده در batch سنتی است ϕ و θ محاسبه می شود و که این همین میانلین در این هر روی B را داده است.

پس ϕ و θ را با استفاده از تراویح میانلین آپدیت می کنیم.

$$\hat{L}(\alpha^B, \phi, \theta) = \sum_{i=1}^B L(\alpha_i; \phi, \theta)$$

$$L(\alpha, \phi, \theta) = \frac{N}{B} \hat{L}(\alpha^B, \phi, \theta)$$

(4)

سؤال ②

(١) در مرحله اول α_t را با α_0 اسلک می‌کنیم و با $N(0, \sigma_t^2)$ جمع می‌کنیم می‌باشد:

$$\alpha_t = \alpha_0 + \sigma_t \varepsilon_t$$

برای اینکه واریانس متغیرهای نهان ما تحریر نمایند باید $\text{Var}(\alpha_t) = 1$ باشد:

$$\text{Var}(\alpha_t) = \alpha_0^2 + \sigma_t^2 = 1 \Rightarrow \alpha_0 = \sqrt{1 - \sigma_t^2}$$

است $\alpha_t = \sqrt{1 - \sigma_t^2}$ پس بطریک

طبق قاعده ما کوفت: (ب)

$$q_r(z_t, z_s | \alpha) = \frac{q(z_t, z_s, \alpha)}{q_r(\alpha)}$$

$$q_r(z_t, z_s, \alpha) = q(z_t | z_s, \alpha) \cdot q(z_s, \alpha)$$

$$q(z_t, z_s | \alpha) = \frac{q(z_t | z_s, \alpha) \cdot q(z_s, \alpha)}{q_r(\alpha)} = q(z_t | z_s, \alpha) q(z_s | \alpha)$$

چون z_t فقط به z_s مارکوف وابسته است می‌باشد: $q(z_t | z_s, \alpha) = q(z_t | z_s)$

$$\Rightarrow q(z_t, z_s | \alpha) = q(z_t | z_s) \cdot q(z_s | \alpha)$$

$$q(z_t | z_s) = N(\alpha_{t|s} z_s, \sigma_{t|s}^2 I) \quad (2)$$

$$\alpha_{t|s} = \frac{\alpha_t}{\alpha_s} \quad , \quad \sigma_{t|s}^2 = \sigma_t^2 - \frac{\alpha_t^2}{\alpha_s} \sigma_s^2$$

$$\left\{ \begin{array}{l} q(z_t | u) = N(\alpha_{t|u}, \sigma_t^2 I) \\ q(z_s | u) = N(\alpha_{s|u}, \sigma_s^2 I) \\ q(z_s, z_t | u) = q(z_t | z_s) q(z_s | u) \end{array} \right.$$

: joint expt

$$\begin{pmatrix} z_s \\ z_t \end{pmatrix} \Big| u \sim N\left(\begin{pmatrix} \alpha_{s|u} \\ \alpha_{t|u} \end{pmatrix}, \begin{pmatrix} \sigma_s^2 & \Sigma_{st} \\ \Sigma_{ts} & \sigma_t^2 \end{pmatrix}\right)$$

$$q(z_t | z_s, u) = N(\mu_{t|s}, \Sigma_{t|s})$$

$$\left\{ \begin{array}{l} \mu_{t|s} = \alpha_t u + \Sigma_{ts} \Sigma_s^{-1} (z_s - \alpha_s u) \\ \Sigma_{t|s} = \sigma_t^2 I - \Sigma_{ts} \Sigma_s^{-1} \Sigma_{st} \end{array} \right.$$

$$\Sigma_{ts} = E \left[(z_t - \alpha_t u) (z_s - \alpha_s u)^T \right] = \alpha_t \alpha_s^T \sigma_u^2 I$$

$$\Sigma_s = \sigma_s^2 I$$

$$\Sigma_{ts} \Sigma_s^{-1} = \alpha_t \alpha_s^T \sigma_u^2 I (\sigma_s^2 I)^{-1} = \frac{\alpha_t}{\alpha_s} \sigma_u^2 I$$

$$\left\{ \begin{array}{l} \mu_{t|s} = \alpha_t u + \frac{\alpha_t}{\alpha_s} (z_s - \alpha_s u) = \frac{\alpha_t}{\alpha_s} z_s \\ \Sigma_{t|s} = \sigma_t^2 I - \left(\frac{\alpha_t}{\alpha_s} \right)^2 \sigma_s^2 I = \left(\sigma_t^2 - \frac{\alpha_t^2}{\alpha_s^2} \sigma_s^2 \right) I \end{array} \right.$$

$$q(z_t | z_s) = N \left(\frac{a_t}{a_s} z_s, \left(\sigma_t^2 - \left(\frac{a_t}{a_s} \right)^2 \sigma_s^2 \right) I \right)$$

$$\begin{cases} a_{t|s} = \frac{a_t}{a_s} \\ \sigma_{t|s}^2 = \sigma_t^2 - \left(\frac{a_t}{a_s} \right)^2 \sigma_s^2 \end{cases}$$

$$\Rightarrow q(z_t | z_s) = N \left(a_{t|s} z_s, \sigma_{t|s}^2 I \right)$$

$$q(z_s, z_t | s) = q(z_s | s) q(z_t | z_s) \quad (1)$$

بهوجو: محسن های قبلی $q(z_s | z_t, x)$ همچنین

$$q(z_s | z_t, x) = \underbrace{q(z_s | x)}_{\text{prior}} \underbrace{q(z_t | z_s)}_{\text{likelihood}}$$

$q(z_s | z_t, x)$ likelihood, prior محسن است وسی ایست. نیز وسی ایست.

likelihood دلیل، $P(x) = N(\mu_A, \sigma_A^2)$ prior دلیل از این دلیل خواهد بود:

$$P(x|y) = N(\bar{\mu}, \bar{\sigma}^2)$$

$$\begin{cases} \tilde{\mu} = \bar{\sigma}^2 (\sigma_A^{-2} \mu_A + \alpha \sigma_B^{-2} y) \\ \tilde{\sigma}^2 = \sigma_A^{-2} + \alpha^2 \sigma_B^{-2} \end{cases}$$

ارتفاع: likelihood, prior محسن است.

$$q(z_s | x) = N(\alpha_s x, \sigma_s^2 I)$$

$$q(z_t | z_s) = N(\alpha_{t|s} z_s, \sigma_{t|s}^2)$$

دلتا

$$q(z_s | z_t, x) = N(\mu_Q(z_t, x; s, t), \sigma_Q^2(s, t) I)$$

$$\sigma_Q^{-2}(s, t) = \sigma_s^{-2} + \alpha_{t|s}^{-2} \quad \sigma_{t|s}^{-2} = \sigma_t^2 / \sigma_{t|s}^2 \sigma_s^2$$

$$\sigma_Q^2(s, t) = \frac{\sigma_{t|s}^2 \sigma_s^2}{\sigma_t^2} \quad \boxed{\mu_Q(z_t, x; s, t) = \frac{\alpha_{t|s} \sigma_s^2}{\sigma_t^2} z_t + \frac{\alpha_s \sigma_{t|s}^2}{\sigma_t^2} x}$$

$$D_{KL}(P||Q) = \int P(x) \log \frac{Q(x)}{P(x)} dx = E_{P(x)} \left[\log \frac{Q(x)}{P(x)} \right] \quad (d)$$

$$\log \frac{q(z_s|z_t, \alpha)}{P_\theta(z_s|z_t)} = \log \left[\frac{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(z-\mu_Q)}}{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(z-\mu_\theta)}} \right] = \\ = \frac{-1}{2\sigma_Q^2} \left[(z-\mu_Q)^2 - (z-\mu_\theta)^2 \right]$$

$$D_{KL} = E_P \left[\log \frac{q}{P_\theta} \right] = E_P \left[\frac{-1}{2\sigma_Q^2} (\mu_Q^2 - \mu_\theta^2 + 2z(\mu_\theta - \mu_Q)) \right]$$

$$\Rightarrow D_{KL} = -\frac{1}{2\sigma_Q^2} \left[2(\mu_\theta - \mu_Q) E_P[z] + \mu_Q^2 - \mu_\theta^2 \right]$$

$$\Rightarrow D_{KL} = \frac{1}{2\sigma_Q^2} \left\| \mu_Q - \mu_\theta \right\|_2^2$$

$$D_{KL} \left(q(z_s|z_t, \alpha) \parallel P_\theta(z_s|z_t) \right) = \frac{1}{2\sigma_{st}^2} \left\| \mu_Q - \mu_\theta \right\|_2^2 \quad (e)$$

$$= \frac{\sigma_t^2}{2\sigma_{st}^2 \sigma_s^2} \frac{\alpha_s^2 \sigma_{st|s}^2}{\sigma_t^2} \left\| \alpha - \hat{\alpha}_\theta(z_t; t) \right\|_2^2$$

$$= \frac{1}{2\sigma_s^2} \frac{\alpha_s^2 \sigma_{st|s}^2}{\sigma_t^2} \left\| \alpha - \hat{\alpha}_\theta(z_t; t) \right\|_2^2 =$$

$$= \frac{1}{2\sigma_s^2} \frac{\alpha_s^2 (\sigma_t^2 - \alpha_{st|s}^2 \sigma_s^2)}{\sigma_t^2} \left\| \alpha - \hat{\alpha}_\theta(z_t; t) \right\|_2^2$$

$$= \frac{1}{2} \frac{\alpha_s^2 \alpha_t^2 / \sigma_s^2 - \alpha_t^2}{\sigma_t^2} \left\| \alpha - \hat{\alpha}_\theta(z_t; t) \right\|_2^2$$

$$D_{KL}(q(z_s|z_t, \omega) || P_\theta(z_s|z_t)) = \quad (1)$$

$$\frac{1}{2} \left[(\text{SNR}(s) - \text{SNR}(t)) \| \alpha - \hat{\alpha}_\theta(z_t; t) \|_2^2 \right]$$

$$L_T(\alpha) = \frac{T}{2} E_{\epsilon \sim N(0, I), i \sim U\{1, T\}} \left[(\text{SNR}(s(i)) - \text{SNR}(t(i))) \| \alpha - \hat{\alpha}_\theta(z_{t(i)}; t(i)) \|_2^2 \right] \quad (2)$$

$$\begin{cases} s(i) = \frac{i-1}{T} \\ t(i) = \frac{i}{T} \end{cases} \Rightarrow s(i) = t(i) - \frac{1}{T} \quad \text{تابعیت فرضی سوال}$$

$$\text{SNR}(s(i)) = \text{SNR}(t(i) - \frac{1}{T})$$

$$\text{SNR}(t(i) - \frac{1}{T}) = \text{SNR}(t(i)) - \frac{1}{T} \text{SNR}'(t(i)) \quad \text{با بسط تابعیت}$$

$$\text{SNR}(t(i) - \frac{1}{T}) - \text{SNR}(t(i)) \approx -\frac{1}{T} \text{SNR}'(t(i))$$

$$\text{SNR}(s(i)) - \text{SNR}(t(i)) \approx -\frac{1}{T} \text{SNR}'(t(i))$$

$$L_T(\alpha) = \frac{T}{2} E_{\epsilon \sim N(0, I), i \sim U\{1, T\}} \left[(-\frac{1}{T} \text{SNR}'(t(i))) \| \alpha - \hat{\alpha}_\theta(z_t; t) \|_2^2 \right]$$

با استعمال و تغییر متغیر فضای کمتر $t \rightarrow (0, 1) \subset U\{1, T\}$ پیوسته تبدیل می شود

$$L_\infty(\alpha) = \lim_{T \rightarrow \infty} L_T(\alpha) = -\frac{1}{2} E_{\epsilon \sim N(0, I)} \int_0^1 \text{SNR}'(t) \| \alpha - \hat{\alpha}_\theta(z_t; t) \|_2^2 dt$$

$$L_\infty(\alpha) = -\frac{1}{2} E_{\epsilon \sim N(0, I), t \sim U(0, 1)} \left[\text{SNR}'(t) \| \alpha - \hat{\alpha}_\theta(z_t; t) \|_2^2 \right]$$

$$\alpha_{t+1} = \alpha_t + \gamma \nabla_\alpha \log p(\alpha_t) + \sqrt{2\gamma} \in \mathbb{R}^n(0, I) \quad (1)$$

$$\alpha_{t+1} = \alpha_t + \gamma \nabla_\alpha \log p(\alpha_t) \quad \text{بعد از حذف نویز:}$$

این عبارت در واقع انجام عمل gradient ascent است و کمین $(P(\alpha_t))$ را درین تابع حداقل می‌داند. این کمین کمک می‌کند به سمت جایی از توزیع برویم π حلالی حضور را دارد آنی سبیت است. در واقع این عمل باعث یافتن فحصی \mathbb{R}^n پر از سورس با توجه به شروع مختلف به قله‌های متفاوتی توزیع برسم. حریت در حقیقت درین مارا به قله‌های پایین توزیع می‌رساند.

در maximum likelihood maximum ها به (نیال تجسسی پارامترهای توزیع $p(x)$) هستم بطوریکه با توجه به راده‌ها، احتمال مالزیم شود. آما در آنها مخلوقات از یک نقطه زنده شروع نمی‌کنند که توزیع حداقلی شود و احتمال حضور سهیل لکه سبیت است. در واقع رایخابه (نیال مالزیم کردن یک نقطه) یا سهیل توزیع موجود هستم. آما در MLE بینیل یافتن پارامترهای توزیع بطوریکه به داره‌هایی خوبی تیکشود، هستم.

ب) استفاده از نویز نرمال از جهات مختلف مهم است. بلکن از دایل این است معملاً شرایط فراسایه Sampling کل فضای توزیع را جستجو می‌کند و در نقاطی میان مکانی نمی‌شود. بلکن دلیل دلیر وجود نویز، نقص regularization است و از این Score function اور فیت شود و generalization خوبی نداشته باشد جلوگیری می‌کند.

یک دلیل دلیر آن در Sampling این است که Sample ها متنوع از قریب نمی‌شوند و میانگین نباشند.

وقتی به قلهای صاف می‌رسد بدلیل این نویز Langevin dynamics اطراف قله را نیز چک می‌کند، تا آندر سینه‌های محلی قرار داشته، در آنها نیز نکند. اما زمانی که به قلهای سینه‌ی می‌رسد نیز بدلیل وجود نویز اطراف حرکت می‌کند و به سهی نتیجه نیز می‌رسد ولی اطراف سینه حرکت می‌کند.

$$q(\alpha) = \frac{1}{m} \sum_{i=1}^m K(\alpha | \alpha^{(i)}) \quad (1) \quad (2)$$

$$K(\alpha | \alpha^{(i)}) = \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^d e^{-\frac{(-\|\alpha - \alpha^{(i)}\|)^2}{2\sigma^2}}$$

$$\nabla_\alpha \log q(\alpha) = \frac{\nabla_\alpha q(\alpha)}{q(\alpha)} = ?$$

$$\nabla_\alpha q(\alpha) = \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{\sqrt{2\pi} \sigma} \right)^d \frac{-2(\alpha - \alpha^{(i)})}{2\sigma^2} e^{-\frac{(-\|\alpha - \alpha^{(i)}\|)^2}{2\sigma^2}}$$

$$\nabla_\alpha q(\alpha) = \frac{1}{m} \sum_{i=1}^m \frac{(\alpha^{(i)} - \alpha)}{\sigma^2} K(\alpha | \alpha^{(i)})$$

$$\nabla_\alpha \log q(\alpha) = \frac{\frac{1}{m} \sum_{i=1}^m \frac{\alpha^{(i)} - \alpha}{\sigma^2} K(\alpha | \alpha^{(i)})}{\frac{1}{m} \sum_{i=1}^m K(\alpha | \alpha^{(i)})} = \frac{\sum_{i=1}^m \frac{\alpha^{(i)} - \alpha}{\sigma^2} K(\alpha | \alpha^{(i)})}{\sum_{i=1}^m K(\alpha | \alpha^{(i)})}$$

ب) متعایب استناده از کرنل میکس در Score matching (2)

۱- استناده از کرنل سیده‌گی ممکن است بالا باشد. اگر تعداد داده‌ها نیز بالا بود آن پیچیدگی بسیار بسته‌تر می‌شود.

۲- حساسیت بالای کرنل ناوسی به میزان σ درد. اگر بسیار بزرگ یا کوچک آشایش شود می‌تواند باعث Over-Smoothing و under-Smoothing ریخته شود.

۳- افزایش بُعد فضای داده باعث ضعیف شدن عملکرد کرنل ناوسی می‌شود. چون نقاط بسته در فاصله نیز (دور از هم در ابعاد بالا قرار می‌شوند) و لینکت تخمین چیزی را کاهش می‌دهند.

۴- کرنل ناوسی ممکن است در نقاط مرزی داده‌ها دچار انحراف و مشکل باشد. آن بخاطر ندرات بودن کرنل ناوسی از حدود واقعی داره است.

$$J_1(\theta) = E_{q(x)} \left[\frac{1}{2} \| \nabla_\theta \log q(x) \|^2 \right] \quad (2)$$

$$J_2(\theta) = E_{q(x, x_0)} \left[\frac{1}{2} \| \nabla_\theta \log q(x|x_0) \|^2 \right]$$

$$J_1(\theta) = E_{q(x)} \left[\frac{1}{2} \| \nabla_\theta \log q(x) \|^2 \right] - K(\theta) + c_1$$

$$c_2 = E_{q(x)} \left[\frac{1}{2} \| \nabla_x \log q(x) \|^2 \right] \quad \text{ابتداست و به } \theta \text{ وابسته است}$$

$$\Rightarrow K(\theta) = E_{q(x)} \left[\langle \nabla_\theta \log q(x), \nabla_x \log q(x) \rangle \right]$$

$$= \int_x q(x) \langle \nabla_\theta \log q(x), \nabla_x \log q(x) \rangle dx$$

$$\begin{aligned}
K(\theta) &= \int_{\alpha} q(\alpha) \left\langle S_{\theta}(\alpha), \frac{\nabla_{\alpha} q(\alpha)}{q(\alpha)} \right\rangle d\alpha \\
&= \int_{\alpha} \left\langle S_{\theta}(\alpha), \nabla_{\alpha} q(\alpha) \right\rangle d\alpha \\
&= \int_{\alpha} \left\langle S_{\theta}(\alpha), \frac{\partial}{\partial \alpha} \int_{\alpha_0} q_0(\alpha_0) q(\alpha | \alpha_0) d\alpha_0 \right\rangle d\alpha \\
&= \int_{\alpha} \left\langle S_{\theta}(\alpha), \int_{\alpha_0} q_0(\alpha_0) \frac{\partial q(\alpha | \alpha_0)}{\partial \alpha} d\alpha_0 \right\rangle d\alpha \\
&= \int_{\alpha} \left\langle S_{\theta}(\alpha), \int_{\alpha_0} q_0(\alpha_0) q(\alpha | \alpha_0) \frac{\partial \log q(\alpha | \alpha_0)}{\partial \alpha} d\alpha_0 \right\rangle d\alpha \\
&= \int_{\alpha} \int_{\alpha_0} q_0(\alpha_0) q(\alpha | \alpha_0) \left\langle S_{\theta}(\alpha), \frac{\partial \log q(\alpha | \alpha_0)}{\partial \alpha} \right\rangle d\alpha_0 d\alpha \\
&= \int_{\alpha} \int_{\alpha_0} q(\alpha, \alpha_0) \left\langle S_{\theta}(\alpha), \frac{\partial \log q(\alpha | \alpha_0)}{\partial \alpha} \right\rangle d\alpha_0 d\alpha \\
&= E_{q(\alpha, \alpha_0)} \left[\left\langle S_{\theta}(\alpha), \frac{\partial \log q(\alpha | \alpha_0)}{\partial \alpha} \right\rangle \right] \\
\Rightarrow J_1(\theta) &= E_{q(\alpha)} \left[\frac{1}{2} \|S_{\theta}(\alpha)\|^2 \right] - E_{q(\alpha, \alpha_0)} \left[\left\langle S_{\theta}(\alpha), \frac{\partial \log q(\alpha | \alpha_0)}{\partial \alpha} \right\rangle \right] \\
&\quad + C_1
\end{aligned}$$

$$J_2(\theta) = E_{q(x)} \left[\frac{1}{2} \|S_\theta(x)\|^2 \right] - E_{q(x|x_0)} \left[\left\langle S_\theta(x), \frac{\partial \log q(x|x_0)}{\partial x} \right\rangle \right] + C_2$$

$$\Rightarrow J_1(\theta) - J_2(\theta) = C_1 - C_2 \rightarrow J_2(\theta) = J_1(\theta) + C_2 - C_1$$

کلیم آباد می شود که: $J_2(\theta) = J_1(\theta) + C_2 - C_1$

$$J_2(\theta) = J_1(\theta) + C$$

$$q(x|x_0) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{\|x-x_0\|^2}{2\sigma^2}} \quad (1)$$

$$\log q(x|x_0) = -d \log (\sqrt{2\pi}\sigma) - \frac{\|x-x_0\|^2}{2\sigma^2}$$

$$\nabla_x \log q(x|x_0) = \frac{-1}{2\sigma^2} \nabla_x \|x-x_0\|^2 = -\frac{x-x_0}{\sigma^2}$$

$$J_2(\theta) = E_{q(x|x_0)} \left[\frac{1}{2} \|S_\theta(x) + \frac{x-x_0}{\sigma^2}\|^2 \right]$$

برای آموزش این مدل بهتر کنیم:

۱. ابتدا از توزیع $q(x|x_0)$ سپل می شویم. این سپل لیری ابتدا با سپل لیری از توزیع

x_0 و سپل با سپل لیری از x در توزیع سرشی به شرط داشت. اگر می شود.

۲. سپل بخش کارهای $\nabla_x \log q(x|x_0)$ را محاسبه می کنیم

۳. محاسبه می کنیم $S_\theta(x)$ Score function سپل

4. از روی دو مرحله قبل تابع لغزینه $J(\theta)$ را حساب می کنیم.
5. با استفاده از الگوریتم gradient descent یا الگوریتم دلیر پسند سازی، مقدار $J(\theta)$ را اپدیت می کنیم تا مینیمم شود.

— استفاده از Langevin Dynamics برای تولید نمونه

$$\alpha_{t+1} = \alpha_t + \delta \nabla_{\alpha} \log P(\alpha_t) + \sqrt{2\delta} \varepsilon \sim N(0, I)$$

1. از یک سپلرندوم α_0 شروع می کنیم.
2. با استفاده از شکله score مقدار $S_\theta(\alpha_t) = \nabla_{\alpha} \log P(\alpha_t)$ را محاسبه و α را اپدیت می کنیم با توجه به فرسخ Langevin dynamics.
3. این مراحل اپدیت را پست سرهم تکرار می کنیم به تعداد کافی تا به توزیع هدف برسیم.

سؤال ۴

1. تخلیل پایداری بیوست

1) رابطه loss به شکل رو به رو است:

$$L(\theta, \psi) = f(\theta \psi) + \text{constant}$$

$$V(\theta, \psi) = \begin{pmatrix} -f'(\theta \psi) \psi \\ f'(\theta \psi) \theta \end{pmatrix} \quad \text{بردار نرادرین} \text{ برابر است با:}$$

$$(\theta, \psi) = (0, 0) \text{ است پس } \text{constant} = L(0, 0) = L(0, \psi) \text{ چون}$$

یک نقطه تصادل برای GAN است همچنان چون $f'(t) \neq 0$ for all $t \in \mathbb{R}$ است که $(\theta, \psi) = (0, 0)$ باشد. پس نقطه $(0, 0)$ نقطه تصادل GAN می باشد.

سوال ④

۱) جاکوبین بردارهای برابر با ۰:

$$V'(\theta, \psi) = \begin{pmatrix} f''(-\theta\psi)\psi^2 & -f'(-\theta\psi) + f''(-\theta\psi)\theta\psi \\ f'(\theta\psi) + f''(\theta\psi)\theta\psi & f''(\theta\psi)\theta^2 \end{pmatrix}$$

در نقطه $\theta = \psi = 0$ جاکوبین مستقل نزیر است:

$$V'(0, 0) = \begin{pmatrix} 0 & -f'(0) \\ f'(0) & 0 \end{pmatrix}$$

با مقدار ویژهای $\lambda_{1,2} = \pm f'(0)i$ که معهومی دارند.

ب) با فرض روابرود:

$$R(\theta, \psi) = \frac{1}{2} (\theta^2 + \psi^2)$$

$$\frac{\partial R(\theta(t), \psi(t))}{\partial t} = -\theta(t) \psi(t) f'(\theta(t) \psi(t)) + \psi(t) \theta(t) f'(\theta(t) \psi(t)) = 0$$

چون کرادیان نسبت به t برابر با ۰ است پس نتیجه می‌شود مقدار R در همه $t \in [0, \infty)$ ثابت است پس مقدار $\theta^2 + \psi^2 = \text{Constant}$ است.

ج) نتیج نخست بلا سُن می‌گردد که گرادیان بالعکس همیمان برای GAN غیر اسپلاین و لغزش یادگیری (یعنی بصورت محلی هملا) است. زیرا مقادیر ویژه جاکوبین محلی بوزرسانی F_h از کیفیت قدر مطلق همی نیز لذتاز ۱ هستند.

پس همکاری خلفی بسته نقطه تکاری در حقیقت پیوسته را می‌شود (برای $h \rightarrow 0$) البته داین میک آنرا پیوسته می‌تواند هنوز بازخ همکاری Sublinear همکار شود.

سؤال ④

$$F_h(\theta, \psi) = (\theta, \psi) + h \nabla(\theta, \psi)$$

(1) (2)

$$\nabla(\theta, \psi) = \begin{pmatrix} -f'(\theta\psi)\psi \\ f'(\theta\psi)\theta \end{pmatrix}$$

$$J = \begin{pmatrix} \Delta I - h f''(\theta, \psi) \psi^2 & -h f'(\theta, \psi) - h f''(\theta\psi) \theta\psi \\ h f'(\theta\psi) + h f''(\theta, \psi) \theta\psi & h f''(\theta\psi) \theta^2 \end{pmatrix}$$

$$J(0,0) = \begin{pmatrix} 1 & -h f'(0) \\ h f'(0) & 1 \end{pmatrix} \quad \text{در نقطه } (0,0) \text{ برابر است:}$$

$$\det(J - \lambda I) = 0 \Rightarrow (1 - \lambda)^2 - (h f'(0))^2 = 0$$

$$1 - \lambda = \pm h f'(0) i$$

$$\boxed{\lambda_{1/2} = 1 \pm h f'(0) i}$$

چون اندازه از پلکانی باشد پس دو مقدار ویرین است و بزرگتر از کمتر است $|\lambda_{1/2}| = \sqrt{1+h^2 f'(0)^2}$ خروج راسید واحد هزار میلیارد.

$$\begin{aligned} \theta_{k+1}^2 + \psi_{k+1}^2 &= (\theta_k - h f'(\theta_k \psi_k))^2 + (\psi_k + h f'(\theta_k \psi_k) \theta_k)^2 \\ &= \theta_k^2 + \psi_k^2 + h^2 f'(\theta_k \psi_k)^2 (\theta_k^2 + \psi_k^2) \\ &\geq \theta_k^2 + \psi_k^2 \end{aligned}$$

پس صورت مینوا در طول آموزش افزایش می‌دهی.

$$F_1(\theta, \psi) = \begin{pmatrix} \theta - h f'(\theta \psi) \psi \\ \psi \end{pmatrix} \quad (2)$$

$$F_2(\theta, \psi) = \begin{pmatrix} \theta \\ \psi + h f'(\theta \psi) \theta \end{pmatrix}$$

جوابیت درین هدایت $(0,0)$ برابر است با:

$$F'_1(0,0) = \begin{pmatrix} 1 & -h f'(0) \\ 0 & 1 \end{pmatrix}$$

$$F'_2(0,0) = \begin{pmatrix} 1 & 0 \\ h f'(0) & 1 \end{pmatrix}$$

$$\mathcal{J} = (F_2 \circ F_1)'(0,0) = F'_2(0,0) \cdot F'_1(0,0) = \begin{pmatrix} 1 & -h f'(0) \\ h f'(0) & 1 - h^2 f'(0)^2 \end{pmatrix}$$

$$\det(\mathcal{J} - \lambda I) = 0 \Rightarrow 1 - h^2 f'(0)^2 - \lambda - \lambda + h^2 \lambda f'(0) + \lambda^2 + h^2 f'(0)^2 = 0$$

$$\Rightarrow \lambda_{1/2} = 1 - \frac{(h f'(0))^2}{2} \pm \sqrt{\left(1 - \frac{h f'(0)}{2}\right)^2 - 1}$$

اگر $h f'(0) \leq 2$ آن‌ها مقدار عویضه همیشہ روی دایره واحد قرار می‌کنند.

اگر $h f'(0) > 2$ آن‌ها مقدار عویضه همیشہ خارج دایره واحد قرار می‌کنند.

اگر معادله عویضه خارج دایره به نظر نباشد، تبدیل دیگر مسئله می‌شود.

$$E_{\hat{\theta} \sim N(\theta, \sigma^2)} [f(\hat{\theta} | \psi)] + E_{\alpha \sim N(0, \sigma^2)} [-f(-\alpha | \psi)] \quad (3)$$

: کاربن را برای objective موقع می سهیم

$$\hat{V}(\theta, \psi) = E_{\hat{\theta}, \alpha} \begin{pmatrix} -\psi f'(\hat{\theta} | \psi) \\ \hat{\theta} f'(\hat{\theta} | \psi) - \alpha f'(-\alpha | \psi) \end{pmatrix}$$

: جاوسن کاربن برابر است با

$$\hat{V}'(\theta, \psi) = E_{\hat{\theta}, \alpha} \begin{pmatrix} -f''(\hat{\theta} | \psi) \psi^2 & -f'(\hat{\theta} | \psi) - f''(\hat{\theta} | \psi) \hat{\theta} \psi \\ f'(\hat{\theta} | \psi) + f''(\hat{\theta} | \psi) \hat{\theta} \psi & f''(\hat{\theta} | \psi) \hat{\theta}^2 + \alpha^2 f'(-\alpha | \psi) \end{pmatrix}$$

$$\hat{V}'(0, 0) = \begin{pmatrix} 0 & -f'(0) \\ f'(0) & 2f''(0) \sigma^2 \end{pmatrix} \quad : (0, 0) \text{ برابر است با}$$

: مقادیر دیگر را بعورت نموده سازویم

$$\det(\hat{V}' - \lambda I) = 0 \Rightarrow -2f''(0) \sigma^2 \lambda + \lambda^2 + f'(0)^2 = 0$$

$$\lambda_{1,2} = \frac{-f''(0) \sigma^2}{2} \pm \sqrt{\frac{f''(0)^2 \sigma^4 - f'(0)^2}{4}}$$

(ب)